

Progetto di Artificial Intelligence: Predizione dell'esito dei match di tennis.

Leonardo Lorenzon

A.A. 2025/2026

1 Introduzione

Il progetto ha l'obiettivo di costruire e confrontare diversi modelli predittivi su dati reali del circuito ATP provenienti da `tennis-data.co.uk` per le stagioni 2019–2025, analizzando sia le prestazioni predittive sia il contributo delle singole variabili al risultato finale. Come emergerà dall'analisi, i modelli convergono verso un'accuratezza di circa il 67–68%, allineandosi alla baseline dei bookmaker senza riuscire a superarla in modo sistematico.

2 Preparazione dei Dati

2.1 Caricamento e Pulizia

Il dataset originale copre 17.048 match distribuiti su sette stagioni (2019–2025). Il primo passo di pulizia ha previsto la rimozione dei match non completati (non contrassegnati come `Completed`) e di colonne irrilevanti come il codice ATP. Sono state inoltre eliminate le colonne che avrebbero costituito una fonte di *data leakage*: i punteggi set per set (`W1–W5`, `L1–L5`) e i set vinti (`Wsets`, `Lsets`), in quanto disponibili solo a partita conclusa.

Inoltre, tra le otto colonne di quote bookmaker originariamente presenti (`Bet365`, `PSL`, `Max`, `Avg`), si è scelto di mantenere esclusivamente le quote medie (`AvgW`, `AvgL`): queste ultime aggregano già l'informazione di tutti i bookmaker monitorati e risultano più robuste agli outlier rispetto alla singola fonte. Tenere tutte e otto le colonne avrebbe introdotto ridondanza, poiché `Max` e `Avg` sono già aggregati che incorporano implicitamente le quote di `Bet365` e `PSL`. Il dataset risultante conta 16.463 match.

2.2 Gestione dei Valori Mancanti

I valori mancanti, sebbene limitati in percentuale (inferiori all'1% per ogni colonna), sono stati trattati con strategie adeguate alla natura di ciascuna variabile.

`Best of` è stato imputato con la moda. Per `WRank` e `LRank` è stato adottato il valore convenzionale 500, indicando un giocatore non classificato. Per `WPts` e `LPts` è stato usato 0, coerentemente con la logica del ranking 500. Le righe con quota media mancante sono state imputate con la mediana della colonna.

In tutti i casi è stato aggiunto un indicatore binario per segnalare la presenza originaria del dato mancante, preservando l'informazione implicita nell'assenza stessa.

2.3 Randomizzazione e Target

Il dataset originale ha una struttura sistematica: la prima colonna è sempre il vincitore e la seconda il perdente. Utilizzare direttamente questa struttura renderebbe impossibile costruire un modello libero da *target leakage*. Per rimuovere questo bias, i ruoli di Giocatore 1 e Giocatore 2 sono stati assegnati casualmente per ciascun match tramite una maschera booleana. La variabile target y vale 1 se il Giocatore 1 ha vinto, 0 altrimenti, ottenendo una distribuzione bilanciata al 50%/50%.

2.4 Encoding delle Variabili Categoricali

Le variabili categoriali sono state trattate diversamente a seconda della loro natura: **Court** è stato convertito in binario (0 = outdoor, 1 = indoor); **Surface** in *one-hot encoding* (tre colonne: Clay, Grass, Hard); **Round** e **Series** in encoding ordinale, poiché entrambe presentano una gerarchia naturale (importanza crescente del turno e del torneo).

2.5 Feature Engineering: Statistiche Storiche

Tutte le statistiche storiche sono state calcolate seguendo un pattern comune: il dataset viene prima ordinato per data, poi per ogni match si leggono i valori accumulati fino a quel momento prima di aggiornarli con il risultato corrente, evitando così qualsiasi forma di leakage temporale. Di ciascuna statistica viene mantenuta solo la differenza tra Giocatore 1 e Giocatore 2, fornendo un'informazione relativa anziché assoluta. Le feature differenziali calcolate sono:

- **win_rate_diff**: differenza nel win rate complessivo su tutti i match disputati.
- **win_rate_surface_diff**: differenza nel win rate sulla superficie specifica del match corrente.
- **recent_win_rate_diff**: differenza nel win rate negli ultimi 20 match.
- **h2h_win_rate_diff**: differenza nel win rate negli scontri diretti tra i due giocatori.
- **rank_diff**, **pts_diff**: differenze grezze nel ranking e nei punti ATP.

2.6 Split Temporale

Il dataset è stato suddiviso in un insieme di addestramento (stagioni 2019–2024, 13.944 match) e un insieme di test (stagione 2025, 2.519 match). La scelta di uno split temporale è fondamentale: uno split casuale mescolando anni diversi significherebbe valutare il modello su dati che precedono nel tempo il training set, violando la causalità e simulando una condizione irrealistica.

3 Modelli

3.1 Baseline

Sono stati adottati due modelli di riferimento molto semplici. Il primo predice come vincitore il giocatore con il ranking ATP più basso (numericamente, quindi il più forte), raggiungendo il 64.79% di accuratezza e AUC-ROC 0.648 sul test set. Il secondo seleziona il giocatore con le quote medie più basse, che implicano una probabilità di vittoria più alta secondo il mercato. La baseline bookmaker raggiunge il 68.04% (AUC-ROC: 0.746): una soglia che, come verrà mostrato, risulta difficile da superare anche per modelli più complessi.

3.2 Metodologia Comune (XGBoost e Random Forest)

Per entrambi i modelli ad albero è stata adottata una sequenza comune di passi:

1. Addestramento iniziale su tutte le 21 feature.
2. Tuning degli iperparametri tramite `RandomizedSearchCV` con `TimeSeriesSplit` (5 fold, 30 candidati), per preservare l'ordinamento cronologico durante la cross-validation.
3. Analisi della feature importance.
4. Selezione automatica del sottoinsieme ottimale di feature tramite RFECV.
5. Confronto con una versione senza quote bookmaker, per isolare il contributo delle sole variabili storiche.

Il `TimeSeriesSplit` è stato preferito al k-fold classico perché quest'ultimo mescolerebbe dati di anni diversi: un fold di validazione potrebbe contenere match del 2019 valutati su un modello addestrato anche sul 2024, violando la causalità temporale.

3.3 XGBoost

Il modello iniziale mostra un marcato overfitting (84.66% training, 65.30% test, AUC-ROC: 0.713). Il tuning degli iperparametri riduce sostanzialmente il gap: 68.42% training, 68.08% test (AUC-ROC: 0.744). La feature importance rivela che il modello si affida quasi esclusivamente alle quote medie (`Avg_P1`, `Avg_P2`), con contributo marginale delle variabili storiche. Il modello RFECV raggiunge il 68.00% (AUC-ROC: 0.743), sostanzialmente invariato. Rimuovendo le quote, l'accuratezza scende al 64.75% (AUC-ROC: 0.710), circa 3 punti in meno.

3.4 Random Forest

Il comportamento della Random Forest rispecchia quello di XGBoost, con overfitting ancora più marcato nel modello iniziale (100% training, 66.93% test, AUC-ROC: 0.729), tipico degli alberi non potati. Dopo il tuning i risultati si allineano: 68.57% training, 67.92% test (AUC-ROC: 0.742), con feature importance dominata dalle quote. Il modello RFECV migliora leggermente: 68.28% (AUC-ROC: 0.744). Rimuovendo le quote, l'accuratezza scende al 65.03% (AUC-ROC: 0.711).

3.5 Rete Neurale Artificiale (ANN)

Per le reti neurali è stata applicata preliminarmente una normalizzazione con `StandardScaler` su tutte le feature.

Sono state testate due architetture:

- **ANN v1**: tre strati densi con dimensioni 64–32–1.
- **ANN v2**: quattro strati densi con dimensioni 128–64–32–1, con `Dropout(0.3)` dopo il primo e il secondo strato nascosto, per ridurre l'overfitting.

Entrambe le architetture condividono: funzione di attivazione ReLU negli strati nascosti e sigmoid nell'ultimo strato; ottimizzatore Adam con learning rate 0.001; funzione di perdita binary cross-entropy; `EarlyStopping` con `patience=10` e `restore_best_weights=True` che monitora la `val_loss` su un 20% del training set usato come validation set.

Negli strati nascosti è stata usata ReLU come funzione di attivazione, mentre l'ultimo strato usa sigmoid per produrre un output in $[0, 1]$ interpretabile come probabilità di vittoria del Giocatore 1.

ANN v1 si ferma all'epoca 15 (migliore all'epoca 5) con accuratezza sul test del 67.49% (AUC-ROC: 0.736) e 68.47% sul training. **ANN v2**, con dropout, raggiunge il 68.48% sul test (AUC-ROC: 0.742) con training al 68.51%. La versione senza quote scende al 64.71% (AUC-ROC: 0.706), confermando il pattern osservato per gli altri modelli.

4 Analisi degli Errori

L'analisi degli errori è stata condotta sull'ANN v2.

Confidenza delle predizioni. Per valutare quando il modello è affidabile, le predizioni sono state suddivise in base alla probabilità stimata: si considera un'alta confidenza quando la probabilità supera 0.7 (o scende sotto 0.3), e bassa confidenza nella fascia intermedia. Sul test set, 787 predizioni su 2.519 (31%) rientrano nella fascia ad alta confidenza, con un'accuratezza dell'80.05%. Le restanti 1.732 (69%) a bassa confidenza scendono al 63.22%. Questo conferma che il modello è ben calibrato: quando esprime certezza alta, sbaglia poco; quando è incerto, l'accuratezza cala significativamente, riflettendo la difficoltà intrinseca di quei match.

Per superficie. L'accuratezza varia leggermente tra le superfici: erba 69.69%, terra 68.80%, cemento 68.09%. Le differenze sono contenute, ma l'erba risulta la superficie più prevedibile, probabilmente perché i giocatori specialisti su questa superficie tendono a dominare con maggiore regolarità rispetto alle altre.

Per turno del torneo. I turni intermedi (quarti/semifinali) mostrano un'accuratezza di 78.89%, molto superiore ai turni iniziali (67.17%) e finali (67.50%). Nei turni intermedi i favoriti hanno già eliminato gli outsider; nelle finali i due finalisti sono di livello troppo simile.

Per gap di ranking. La relazione è netta: gap piccolo (0–10) 65.85%, medio (10–50) 65.67%, grande (50–200) 72.44%, enorme (200+) 72.08%. Match tra giocatori vicini nel ranking sono intrinsecamente meno prevedibili.

5 Risultati Finali

La tabella seguente riassume le prestazioni di tutti i modelli sul test set (stagione 2025).

Modello	Accuracy	AUC-ROC
Baseline Ranking	0.6479	0.6479
Baseline Bookmaker	0.6804	0.7456
XGBoost (tuned)	0.6808	0.7441
XGBoost (RFECV)	0.6800	0.7432
XGBoost (no odds)	0.6475	0.7099
Random Forest (tuned)	0.6792	0.7425
Random Forest (RFECV)	0.6828	0.7440
Random Forest (no odds)	0.6503	0.7107
ANN v1	0.6749	0.7359
ANN v2	0.6848	0.7417
ANN (no odds)	0.6471	0.7055

Tabella 1: Confronto delle prestazioni sul test set (stagione 2025).

La maggior parte dei modelli con quote si attesta intorno al 68% di accuratezza, a parità con la baseline bookmaker. La rimozione delle quote causa un calo uniforme di circa 3–4 punti percentuali, scendendo al 64–65%, con una riduzione dell’AUC-ROC di circa 0.033–0.038. Fra i modelli con quote, XGBoost (68.08%), Random Forest RFECV (68.28%) e ANN v2 (68.48%) mostrano prestazioni molto simili; ANN v1 (67.49%) si colloca leggermente al di sotto.

6 Conclusioni

Tutti i modelli raggiungono circa il 68% di accuratezza, pari alla baseline bookmaker. Le quote di mercato aggregano l’informazione disponibile in modo quasi ottimale, come confermano la feature importance dominante e il calo uniforme di 3 punti alla loro rimozione.

Le variabili storiche mantengono un contributo autonomo del 64–65% senza quote, superiore alla baseline di ranking (64.79%): le statistiche di gioco catturano informazione non completamente riflessa nel ranking ATP.

I modelli con quote si equivalgono: Random Forest RFECV (68.28%), XGBoost (68.08%) e ANN v2 (68.48%) differiscono di meno di mezzo punto; ANN v1 (67.49%) si colloca appena al di sotto. Per gli alberi la feature importance è disponibile direttamente; per l’ANN la struttura a strati nascosti non permette questa lettura immediata.